

Jeden cel, trzy mechanizmy: spektrum jakości – pamięć – obliczenia w predykcji następnego znaku

kolektyw **Slayer**
`github.com/slayerlabs/micro-models`

czerwiec 2026

Streszczenie

Każdy model językowy realizuje jeden cel — $p(\text{następny} \mid \text{poprzednie})$ — ale różnymi *mechanizmami*: od twardego zliczania (n-gram) po miękką uwagę (transformer). Na w pełni audytowalnej mikro-skali (char-level, korpus muzyki w notacji ABC, trening w minuty na CPU) mierzymy trzech zawodników na jednym podziale. Wynik kontrintuicyjny: **n-gram rzędu 6 osiąga perplexity 3,90, niemal jak mini-transformer (3,80)** — co *nie* znaczy, że n-gram wygrywa. Perplexity to jeden wymiar; dorzucenie **pamięci** i **obliczeń** pokazuje, że n-gram i transformer to przeciwne rogi tego samego trójkąta, a różnicą, której perplexity nie widzi, jest **generalizacja**. Raportujemy też, czego *nie* zmierzaliśmy.

Status: DRAFT. Zsyntezowany z notatek dialektycznych w `warsztat-spektrum/`. Kod i wagi otwarte.

1 Jeden cel, spektrum mechanizmów

n-gram i transformer to nie „stary” i „nowy” model, lecz dwa mechanizmy tego samego celu: **zliczanie** vs **uwaga**. Między nimi leży ciągle spektrum. Żeby je zobaczyć, schodzimy na najmniejszy, audytowalny koniec: poziom znaku, melodie w notacji ABC, modele trenowane w minuty na CPU — wszystko na jednym podziale train/val, więc perplexity (jak bardzo model jest zaskoczony prawdziwym następnym znakiem; niższe = lepiej) jest bezpośrednio porównywalne.

2 Trzej zawodnicy

- **n-gram** — zlicza częstości znaków po oknie k i czyta p z tablicy (interpolacja rzędów + backoff).
- **NPLM** (Bengio i in., 2003) — „neuronowy n-gram”: mały MLP nad embeddingami ostatnich N znaków; stałe okno, ale *uczy się reprezentacji, nie tablicy*.
- **mini-GPT** — transformer z uwagą: sam waży, które wcześniejsze znaki są istotne; zmienny, długi kontekst.

3 Wynik 1: perplexity — i niespodzianka

Model	mechanizm	val ppl
n-gram rząd 1	zliczanie, okno 1	11,86
n-gram rząd 3	zliczanie, okno 3	5,19
n-gram rząd 6	zliczanie, okno 6	3,90
NPLM, okno 8	MLP, stałe okno	4,41
NPLM, okno 16	MLP, stałe okno	4,38
mini-GPT	uwaga, okno 128	3,80

n-gram dobija do transformera przy rzędzie 5–6. Na samym perplexity to prawie remis. To nie koniec historii — to jej początek.

4 Wynik 2: trójkąt zasobów, nie jedna liczba

Pamięć. n-gram kupuje jakość pamięcią rosnącą lawinowo: z 52 kontekstów (rząd 1) do **508 tys.** (rząd 6), przy malejącym zysku (rz. 5→6: ppl 3,95→3,90). NPLM: ~41 tys. parametrów; mini-GPT: ~800 tys.

Obliczenia. mini-GPT robi ~1,8 mln FLOPs na token — o rzędy wielkości więcej niż n-gram (~7 odczytów z tablicy). **Compute jest niemal odwrotnością pamięci.**

Generalizacja. n-gram *nie ekstrapoluje*: nieznany kontekst → backoff do krótszego, w skrajności do unigramu — rekombinuje widziane, nie tworzy nic dla nowego wzorca. Sieci neuronowe uogólniają po podobieństwie w przestrzeni embeddingów.

Trójkąt. To nie „kto ma niższy ppl”, lecz wybór, który zasób jest tani: n-gram — tani compute, droga pamięć, zero generalizacji; transformer — drogi compute, zwarty, generalizuje; NPLM — most.

5 Uczciwie: czego NIE zmierzaliśmy

n-gram wygląda aż tak dobrze, bo muzyka jest repetytywna — wiele 6-gramów z walidacji występuje dosłownie w treningu. Czystego testu ekstrapolacji (walidacja ze *świeżych* melodii) jeszcze nie zrobiliśmy; przewidujemy, że tam n-gram siądzie, a sieci utrzymają. Nie udajemy, że to już pokazaliśmy — to następny eksperyment.

6 Most do praktyki Slayera (konceptyjny)

Ostrzeżenie: nie zestawiamy tych liczb z produkcyjnymi — char-ppl na muzyce a accuracy na polskich zadaniach to *różne osie*. Most jest konceptyjny: przenosi się **ten sam cel** (predykcja następnego tokena, od char-LM po model 9B) i **ta sama dyscyplina pomiaru** (held-out, dekontaminacja, brak benchmaxingu) — zmienia się tylko metryka. W skali produkcyjnej „mierzenie predykcji następnego znaku” staje się polskim leaderboardem (LLMzSzŁ, PES, PoQuAD, FLORES, Belebele) z dekontaminacją korpusów. Napięcie pamięć vs generalizacja z zabawki to to samo napięcie w roadmapie: tani, składalny, suwerenny polski model i ewaluacja, której nie da się oszukać.

7 Spróbuj sam

Cały przykład jest uruchamialny na CPU w minuty.

```
git clone https://github.com/slayerlabs/micro-models
# music-experts/ : trening eksperta + generacja + porownanie n-gram/NPLM/GPT
```

Następny szczebel: weź „good first issue”, odpal benchmark lokalnie i zgłoś wynik — jesteś w środku, z publicznym, podpisanym wkładem.

8 Jak pracujemy (Slayer)

Żadnej tezy bez dowodu. Publikujemy też wyniki negatywne, a własne pomiary przepuszczamy przez adversarialny audyt — przy pokrewnym eksperymencie złapaliśmy tak własny błąd metryki i wycofaliśmy ją, zanim cokolwiek ogłosiliśmy.