

Od n-gramu do transformera: spektrum mechanizmów predykcji następnego znaku (studium na mikro-skali)

Arkadiusz Słota
kolektyw **Slayer**
github.com/slayerlabs/micro-models

czerwiec 2026

Streszczenie

Jeden cel — predykcja następnego tokena — realizuje cała rodzina mechanizmów: od twardego zliczania (n-gram) po miękką uwagę (transformer). Na char-level korpusie muzyki (jigi w notacji ABC, jeden wspólny podział train/val) mierzymy perplexity wzdłuż tego spektrum: n-gram (przemiatanie rzędów 1–6), NPLM [1] (neural n-gram, przemiatanie okna) oraz mini-GPT z uwagą [2]. Wynik *nie* jest naiwnym uszeregowaniem: n-gram rzędu 6 (ppl 3,90) niemal dorównuje GPT (3,80), ale jako tablica ~508 tys. kontekstów bez zdolności generalizacji; NPLM kompresuje ten sam pomysł do ~40 tys. parametrów (ppl ~4,4); GPT wygrywa zmiennym, długim kontekstem. Wniosek: spektrum porządkuje nie sam perplexity, lecz **trójkąt ppl–pamięć–generalizacja**.

1 Motywacja

n-gram i transformer bywają stawiane jako „stary” i „nowy” model języka, ale łączy je jeden cel: $p(x_t | x_{<t})$. Różnią się *mechanizmem*: n-gram **zlicza** wystąpienia w stałym oknie i czyta prawdopodobieństwo z tablicy; transformer **uczy** reprezentacji i waży kontekst uwagą. Między nimi leży ciągle spektrum (m.in. NPLM [1], kNN-LM [3], infini-gram [4]). Pracujemy na jego najmniejszym, w pełni audytowalnym końcu — modele dość małe, by je zrozumieć i wytrenować w minuty na CPU — i pytamy: *co dokładnie kupuje każdy krok po spektrum?*

2 Układ pomiaru


Korpus: melodie folkowe (jigi) w ABC, poziom znaku; 2,45 mln znaków, słownik 52. Jeden wspólny podział 90/10 (train/val) dla *wszystkich* modeli, więc perplexity ($\text{ppl} = e^{\overline{\text{CE}}}$ na held-out) jest bezpośrednio porównywalne. Surowych danych nie redystrybuujemy (odtwarzalne ze skryptów).

- **n-gram** (zliczanie): interpolacja liniowa rzędów $0..M$ (wagi $\propto 2^o$, renormalizowane po rzędach aktywnych) z floorem unigramowym add- k — poprawny rozkład, skończone ppl. Przemiatamy $M = 1..6$.
- **NPLM** [1] (neural n-gram): MLP nad konkatencją embeddingów N ostatnich znaków, bez uwagi, stałe okno. Przemiatamy $N \in \{4, 8, 16\}$ (~25–74 tys. parametrów).
- **mini-GPT** [2]: dekodery transformer (4 warstwy, 4 głowice, $d=128$, okno 128; ~0,8 mln param) — uwaga = zmienny, długi kontekst.

3 Wyniki

Model	Mechanizm	val ppl	Rozmiar
n-gram rząd 1	zliczanie, okno 1	11,86	52 konteksty
n-gram rząd 3	zliczanie, okno 3	5,19	13,9 tys.
n-gram rząd 5	zliczanie, okno 5	3,95	215 tys.
n-gram rząd 6	zliczanie, okno 6	3,90	508 tys. kontekstów
NPLM, okno 4	MLP, stałe okno	4,52	25 tys. param
NPLM, okno 8	MLP, stałe okno	4,41	41 tys. param
NPLM, okno 16	MLP, stałe okno	4,38	74 tys. param
mini-GPT	uwaga, okno 128	3,80	~800 tys. param

Tabela 1: Perplexity na wspólnym held-out (char-level jigi). Pełne przemiatanie n-gramu: 11,86/7,14/5,19/4,29/3,95/3,90 dla rzędów 1–6 (liczba kontekstów: 52/1,2K/13,9K/67,6K/215K/508K).



Rysunek 1: **Spektrum mechanizmów predykcji następnego znaku.** n-gram poprawia ppl z rzędem (zapamiętuje coraz dłuższe dosłowne konteksty), ale liczba kontekstów eksploduje (do 508 tys.). Na tym repetytywnym korpusie n-gram rzędu 6 (3,90) niemal dorównuje GPT (3,80), a NPLM (stałe okno, ~40 tys. param) osiąga ~4,4. Perplexity nie różnicuje mocno mechanizmów — różnica leży w *pamięci* i *generalizacji* (patrz dyskusja).

4 Dyskusja

n-gram: pamięć rośnie szybciej niż jakość. Perplexity spada monotonicznie z rzędem (11,86 → 3,90), lecz liczba przechowywanych kontekstów rośnie ~2–3-krotnie na rząd (do 508 tys.). To *tablica look-up*: dla kontekstów niewidzianych w treningu n-gram nie generalizuje, tylko cofa się (backoff) do krótszego okna. Że rząd 6 niemal dorównuje GPT, wynika z **repetytywności muzyki** — wiele 6-gramów z val występuje dosłownie w train. To zasługa *pamiętania*, nie rozumienia; perplexity na repetytywnych danych nagradza pamiętanie.

NPLM: kompresja i generalizacja zamiast tablicy. Ten sam pomysł (stałe okno), ale predyktor jest *neuronowy*: gładka funkcja nad embeddingami, ~ 40 tys. parametrów zamiast setek tysięcy kontekstów. Płaci nieco wyższym ppl ($\sim 4,4$), ale uczy się *reprezentacji* (podobne konteksty $\rightarrow$ podobne predykcje), więc generalizuje na konteksty niewidziane. To jest „most”: mechanika n-gramu, lecz waga w nauczonych cechach, nie w zliczeniach.

Transformer: zmienny, długi kontekst. Uwaga [2] znosi sztywne okno — model sam waży, które wcześniejsze znaki są istotne — i osiąga najlepszy ppl (3,80) kosztem $\sim 0,8$ mln parametrów. Dalsze punkty spektrum (poza tym studium): kNN-LM [3] interpoluje sieć z wyszukiwaniem najbliższych sąsiadów, a infini-gram [4] realizuje n-gram o nieograniczonym n przez suffix array (zliczanie bez limitu długości kontekstu).

Teza. Spektrum porządkuje **trójkąt ppl–pamięć–generalizacja**, nie sam perplexity. Twarde zliczanie kupuje niski ppl pamięcią i bez generalizacji; sieć neuronowa kupuje generalizację i zwartość kosztem odrobiny ppl; uwaga kupuje zmienny kontekst kosztem parametrów. Na repetytywnym, char-level korpusie różnica w ppl między końcami spektrum jest *mała* — to przestroga: perplexity sam nie rozstrzyga o „lepszym” mechanizmie.

5 Ograniczenia

Jedna domena (jigi), poziom znaku, mikro-skala; prosta interpolacja n-gramu (wagi 2^o); perplexity nie mierzy generalizacji wprost (kluczowe przy n-gramie). Wszystkie liczby pochodzą z jednego ziarna treningu. Kod ewaluacji (`ngram_eval.py`, `nplm.py`) i wagi GPT są otwarte w repozytorium.

Literatura

- [1] Y. Bengio, R. Ducharme, P. Vincent, C. Jauvin. *A Neural Probabilistic Language Model*. JMLR 2003.
- [2] A. Vaswani i in. *Attention Is All You Need*. NeurIPS 2017.
- [3] U. Khandelwal, O. Levy, D. Jurafsky, L. Zettlemoyer, M. Lewis. *Generalization through Memorization: Nearest Neighbor Language Models*. ICLR 2020. arXiv:1911.00172.
- [4] J. Liu i in. *Infini-gram: Scaling Unbounded n-gram Language Models to a Trillion Tokens*. COLM 2024. arXiv:2401.17377.