

Kompozycja małych ekspertów muzycznych: baseline’y, bezstratny stitch i uczciwy wynik negatywny

Arkadiusz Słota
kolektyw **Slayer**
github.com/sl原因erlabs/micro-models

czerwiec 2026

Streszczenie

Trenujemy cztery modele GPT ($\sim 0,8$ mln parametrów) *od zera* na monofonicznej muzyce w notacji ABC (jig irlandzki, sopran chorałów Bacha, walc, reel). Mimo małego rozmiaru uczą się struktury muzycznej — metrum, sygnatur tonacji, kadencji — z samej predykcji następnego znaku, bez wpisanej w kod teorii muzyki. Następnie badamy, czy takich małych ekspertów da się *składać*. Trzy wnioski: (i) mechanizm stitchu jest **bezstratny** — wytrenowany liniowy mapper na styku pośrednim odtwarza baseline; (ii) płaski **ensemble** dwóch ekspertów bije każdy pojedynczy model na zbalansowanym zadaniu mieszanym; ale (iii) **stitch reprezentacji** (liniowy) tego ensemble *nie bije*. Raportujemy ten wynik negatywny otwarcie i wskazujemy warunki — wymuszony wspólny kontrakt, bogatsze mappery — w których kompozycja na poziomie reprezentacji mogłaby wygrać.

1 Motywacja

Interesują nas *mikro-modele*: sieci dość małe, by zrozumieć je od początku do końca i wytrenować w minuty. Pytanie przewodnie: czy wielu małych, poprawnych ekspertów da się **złożyć** w coś większego — taniej i w sposób modularny — zamiast trenować jeden duży model. Predykcja następnego tokena to wspólny cel od n-gramu po transformer; my pracujemy na jego najmniejszym praktycznym końcu. Zgodnie z zasadami kolektywu Slayer (twardy pomiar, jawny koszt, brak benchmaxxingu) raportujemy też wyniki negatywne.

2 Modele i dane

Wszyscy eksperci dzielą jedną architekturę: transformer dekodujący, **4 warstwy**, **4 głowice**, $d_{\text{model}} = 128$, **okno 128 znaków**, poziom znaku (char-level). Trening: strata cross-entropy, AdamW ($\text{lr} = 3 \cdot 10^{-4}$), warmup + cosine, ~ 2000 kroków, CPU (minuty). Dane: melodie folkowe z thesession.org (ABC) oraz sopran chorałów Bacha przez music21; surowych danych nie redystrybuujemy (odtworzalne ze skryptów).

Modele uczą się realnej struktury: generują poprawne ABC, respektują metrum i sygnatury tonacji (np. $\sharp F$ w G-dur pojawia się samo, bez błędnych krzyżyków) — wyłącznie z predykcji następnego znaku.

Ekspert	Styl / render	Dane (znaki)	Val ppl
jig	jig irlandzki 6/8	2,45 mln	3,80
Bach	sopran chorału (barok)	79 tys.	2,09*
walc	liryczny 3/4 → fortepian	789 tys.	~4,4
reel	żwawy fiddle 4/4 → skrzypce	3,90 mln	~4,9

Tabela 1: Eksperci. *ppl Bacha nieporównywalne 1:1 (mniejszy słownik + bardzo powtarzalne dane).


3 Eksperymenty kompozycji

E0 — self-stitch (mechanizm). Wstawiamy liniowy mapper $g \in \mathbb{R}^{128 \times 128}$ na styku po bloku 2 tego samego modelu i zamrażamy resztę. g = identyczność daje *dokładnie* baseline (poprawność forwardu); g losowy psuje model (ppl 122), a trening samych 16 tys. parametrów g odbudowuje go do baseline ($\Delta\text{ppl} +0,03$). **Waliduje to mechanizm, nie tezę kompozycji.**

Ensemble (płaskie ważenie). Dwóch ekspertów o wspólnym słowniku; w każdym kroku logits = $\alpha A + (1 - \alpha) B$. Baseline do pobicia.

E1 — stitch reprezentacji. Front eksperta $A \times g \times$ back eksperta B (wspólny słownik), trening tylko g . *Lekcja metodologiczna:* pierwszy pomiar dał „stitch bije ensemble” — okazało się artefaktem (held-out ze sklejonych korpusów wyszedł niemal czysty reel). Po zbalansowaniu (val = 50% walc + 50% reel) wynik się odwrócił. Setup ewaluacji jest częścią dowodu.

4 Wyniki



Rysunek 1: Zbalansowany held-out (walc + reel po równo). **Ensemble bije oba pojedyncze modele; stitch reprezentacji $\approx$ ensemble (minimalnie gorszy).**

Dwa wnioski: (1) **ensemble (5,15) bije oba pojedyncze modele** (walc 6,20, reel 5,87) — łączenie ekspertów realnie pomaga na zadaniu mieszanym. (2) **Stitch (5,18) $\approx$ ensemble (5,15)** — liniowy stitch reprezentacji nie pobił prostego baseline’u.

5 Dyskusja

Wynik (2) jest negatywny, ale spodziewany: zrobiliśmy najtrudniejszy przypadek — *post-hoc*, mapper liniowy, bez wymuszonego wspólnego kontraktu, z pominięciem testu wyrównania geometrii. Dwa modele trenowane niezależnie mają różne geometrie reprezentacji; pojedynczy liniowy mapper na jednym styku nie wyrównuje ich lepiej niż uśrednianie wyjść. Drogi do ewentualnej przewagi: (a) **wymuszony kontrakt** — trenować obu ekspertów przeciw wspólnej, zamrożonej głowicy od zera [4, 3]; (b) **bogatszy mapper** — słownik cech / sparse autoencoder zamiast liniowego [6, 7]; (c) najpierw sprawdzić, czy niezależne modele tej samej architektury są w ogóle liniowo zszywalne [1, 2]. Prosty baseline (ensemble [5]) jest mocny — złożoność musi dopiero zasłużyć na siebie.

Asymetria porównania. Nasz stitch jest *kierunkowy* (front $A \times g \times$ głowa B), a ensemble *symetryczny* (miesza obie głowy). Uczciwszy test pytania „czy kompozycja reprezentacji bije mieszanie wyjścia” to *symetryczna* fuzja reprezentacji do wspólnej głowy — nie unieważnia remisu, ale go niuansuje.


Pomiar zgodności reprezentacji (CKA na mikro-skali). Sprawdziliśmy wprost, czy niezależnie trenowane mikro-modele dzielą geometrię — metryką CKA [12], względem *właściwego* nulla (dwa *losowe* modele tej samej architektury), jako funkcję skali (Rys. 2). **Tak: zgodność jest wysoka i wczesna** — CKA modeli same-task (różny seed) $\approx 0,94$ już od 0,05M, *znacznie* powyżej nulla losowy–losowy (0,44), równomiernie we wszystkich blokach (nie tylko w warstwie wejściowej); także między stylami (jig–walc 0,84). To wspiera interpretację E1: geometrie są wspólne, więc remis stitch $\approx$ ensemble wynika z **redundancji** (mało komplementarnej informacji), nie z niezgodności; wspólna geometria otwiera za to interoperacyjność przez reprezentacje względne [11]. *Uczciwie (po adversarialnym audycie analizy):* (i) to *stabilność reprezentacji względem inicjalizacji* przy tych samych danych, a nie „platońska konwergencja” w sensie [10] (ta wymaga różnych danych/modalności); (ii) metryka mutual-kNN okazała się **nieprzydatna na tej skali** — jej null losowy–losowy ($\approx 0,68$) jest równie wysoki jak modele trenowane, więc mierzy strukturę wejścia, nie wyuczoną zgodność; raportujemy zatem wyłącznie CKA. *Uwaga do dalszego routingu:* domeny rozłączne po metrum (6/8 vs 4/4) pozwalają routerowi „oszukać” po jednym tokenie nagłówka — testy routingu wymagają domen w *tych samych* metrum.

6 Wnioski

Pokazaliśmy, że (i) malutki char-LM uczy się struktury muzycznej z samej predykcji następnego znaku oraz (ii) *ensemble* małych ekspertów bije pojedynczy model na zadaniu mieszanym — kompozycja ma wartość. Nie pokazaliśmy (jeszcze), że *stitch na poziomie reprezentacji* bije ten ensemble; ten wynik negatywny wskazuje konkretne, sfalsyfikowalne kierunki dalej. Lekcję metodologiczną traktujemy jako *główną*, nie *poboczną*: **setup ewaluacji jest częścią dowodu** — pierwszy pomiar E1 dał pozorne „stitch bije ensemble”, okazał się artefaktem skażonego held-outu (sklejone korpusy $\rightarrow$ walidacja niemal czysty reel), i sami go obaliliśmy przed publikacją. Cały kod, wagi i notatki badawcze (dialektyka teza $\leftrightarrow$ antyteza $\rightarrow$ synteza) są otwarte w repozytorium.

Literatura

- [1] K. Lenc, A. Vedaldi. *Understanding image representations by measuring their equivariance and equivalence*. CVPR 2015.



Rysunek 2: **Zgodność reprezentacji niezależnie trenowanych mikro-modeli (same-task, różny seed) w funkcji rozmiaru.** CKA [12] i mutual-kNN ($k=10$) między wyjściami bloków, uśrednione po warstwach; słupki błędu = $\pm$ std (próbkowe) po 3 parach seedów. Linie odniesienia: null *losowy-losowy* osobno dla każdej metryki (dwa nietrenowane modele tej samej architektury). *Wniosek (po adversarialnym audycie analizy):* CKA modeli trenowanych ($\approx 0,94$) leży **daleko powyżej** swojego nulla (0,44) — realna wspólna geometria, wysoka już na 0,05M. Natomiast mutual-kNN (0,46–0,73) jest na poziomie *swojego* nulla ($\approx 0,68$) — metryka zdominowana strukturą wejścia, *nie* świadczy o wyuczonej zgodności; dlatego wnioskujemy wyłącznie z CKA. Właściwy null i wybór metryki mają znaczenie.

- [2] Y. Bansal, P. Nakkiran, B. Barak. *Revisiting Model Stitching to Compare Neural Representations*. NeurIPS 2021.
- [3] G. Stoica i in. *ZipIt! Merging Models from Different Tasks without Training*. ICLR 2024.
- [4] S. Ainsworth, J. Hayase, S. Srinivasa. *Git Re-Basin*. ICLR 2023.
- [5] B. Lakshminarayanan, A. Pritzel, C. Blundell. *Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles*. NeurIPS 2017.
- [6] A. van den Oord, O. Vinyals, K. Kavukcuoglu. *Neural Discrete Representation Learning (VQ-VAE)*. NeurIPS 2017.
- [7] T. Bricken i in. *Towards Monosemanticity (sparse autoencoders)*, 2023; H. Cunningham i in., arXiv:2309.08600.
- [8] Y. Bengio i in. *A Neural Probabilistic Language Model*. JMLR 2003.
- [9] U. Khandelwal i in. *Generalization through Memorization: Nearest Neighbor Language Models*. ICLR 2020.
- [10] M. Huh, B. Cheung, T. Wang, P. Isola. *Position: The Platonic Representation Hypothesis*. ICML 2024. arXiv:2405.07987.
- [11] L. Moschella i in. *Relative representations enable zero-shot latent space communication*. ICLR 2023. arXiv:2209.15430.

- [12] S. Kornblith, M. Norouzi, H. Lee, G. Hinton. *Similarity of Neural Network Representations Revisited*. ICML 2019. arXiv:1905.00414.